

跨 seed many-to-many SAE 匹配：数学基础、完整证明与实验路线

Contribution-Balanced Subspace Matching (CBSM) 与 Cross-Seed Concept Alignment and Distillation (CCAD)

人类阅读完整版 • 2026-08-31

本文将目标导向研究报告、THM-CBSM-001-009 的完整证明、证明修订记录、反例审计和实验路线合并为一份自治文档。它是 many-to-many feature matching / subspace-aligned matching 的数学基础，但不是已经完成实证或全球新颖性验证的论文。

阅读说明与结论状态

这是不是数学 base?

是。它的核心不是“两个 decoder spans 看起来相似”，而是把两个 seed 的 feature groups 映射为同一共享 hook 上的输入依赖解码贡献过程：

$$Y_I^{(s)}(x) = D_I^{(s)} Z_I^{(s)}(x).$$

然后同时比较：

- 1. 动态功能是否相同，即 summed contribution 是否在 paired inputs 上一致；
- 2. decoder ranges 是否相同，即子空间是否出现冗余、膨胀或未使用方向；
- 3. 该一致性是否能转移为 held-out ablation、replacement 和 steering 的跨 seed 因果一致性；
- 4. 共识贡献是 rank 1，还是必须保留为 rank- r concept block。

因此它既是 many-to-many feature matching 的数学 base，也是 subspace alignment 的一个更严格版本：span alignment 只是其中一个坐标，dynamic contribution alignment 才是主要功能对象。

证明是否完整?

本卷第二部分给出完整内部证明。当前诚实状态如下：

结果	可证明状态	必要边界
THM-CBSM-001	PROVABLE AS STATED	采用 partition-indecomposable，而非错误的集合包含极小性；只处理固定 matched supports
Corollary 4.3	PROVABLE AFTER EXTRA ASSUMPTIONS	需要 block atomicity 与无单边 zero-sum subset
THM-CBSM-002	PROVABLE AS STATED	BCC 排除双零/退化向量
THM-CBSM-003	PROVABLE AS STATED	PSC 排除 rank-zero groups
THM-CBSM-004	PROVABLE AS STATED FOR THE REPRESENTED PROCESS	一般 $GL(r)$ 变换未必保持 ReLU、稀疏性或固定 encoder class
THM-CBSM-005	PROVABLE AS STATED	Hadamard witness 是分离例，不证明 CBSM 在所有数据上占优
LEM-CBSM-006	PROVABLE AS STATED	需要有限、预先固定的候选族与 population margin
THM-CBSM-007	PROVABLE AS STATED UNDER EXPLICIT ASSUMPTIONS	centering constants 必须在独立 split 冻结；bounded observations；不可复用 audit data 选候选
THM-CBSM-008	PROVABLE AS STATED	support-minimal 与 partition-indecomposable 的对应需要无单边 zero-sum subset
THM-CBSM-009	PROVABLE AS STATED	exact clause 对任意 deterministic downstream map；approximate clause 需要 Lipschitzness

证明审计曾发现并修复六类问题：错误的极小性定义、orthogonal-block uniqueness 的隐藏假设、zero-rank PSC、把代数 gauge 误说成 SAE-class invariance、audit-sample centering 引起的依赖，以及 Hadamard sequence 的量词不清。完整修订记录见第三部分。

尚未完成的门：没有独立外部 proof reviewer；真实 SAE 实验尚未完成；数学组织方式的 paper-level 新颖性仍需继续检索。因此本文使用“内部完整证明”，不使用“外部形式验证”或“已证全新数学”措辞。

全卷结构

- 跨 seed many-to-many SAE 匹配：数学基础、完整证明与实验路线
- 阅读说明与结论状态
 - 这是不是数学 base？
 - 证明是否完整？
 - 全卷结构
- 从跨 seed 子空间一致性到可训练的概念单元
 - 一份面向顶会实证的数学、算法与实验研究蓝图
 - 0. 结论先行
 - 1. 我们究竟要证明什么
 - 1.1 研究对象
 - 1.2 “同一概念”不能只靠一句自然语言解释定义
 - 1.3 主假设
 - 2. 文献线索：每篇工作给了什么，又没有给什么
 - 2.1 核心先例矩阵
 - 2.2 SALVE 留下的最直接实验缺口
 - 2.3 Stable SAE 暴露的公平性陷阱
 - 2.4 其他紧邻工作对主张边界的影响
 - 3. 方法总览：CCAD，而不是一个孤立 metric
 - 3.1 输入与输出
 - 3.2 三种不要混为一谈的“subspace intervention”
 - 3.3 为什么现实输出应是重叠超图
 - 4. 数学核心一：动态贡献一致性
 - 4.1 中心化过程与 Hilbert 空间
 - 4.2 Balanced Contribution Consistency
 - 4.3 高效 Gram 恒等式
 - 4.4 Projector Subspace Consistency
 - 4.5 抵消审计
 - 5. 数学核心二：为何 one-to-one 可以任意差
 - 5.1 Hadamard 分离定理（已证明）
 - 5.2 Gauge 与 split/merge 不变性（已证明）
 - 6. 数学核心三：匹配与干预之间的桥
 - 6.1 直接跨 seed 替换
 - 6.2 同 hook 因果可交换性（已证明）
 - 6.3 多 seed 共识恒等式（经典 Hilbert-space ANOVA）
 - 6.4 不能保证“总有有意义的局部解”

- 7. 数学核心四：何时蒸馏为单 feature，何时保留 block
 - 7.1 共识贡献矩阵
 - 7.2 Rank-adaptive 蒸馏判据（Eckart-Young 的直接应用）
 - 7.3 “monosemantic” 应描述语义，而非维数
- 8. 候选发现与 many-to-many 匹配算法
 - 8.1 为什么不能对所有 subsets 暴力搜索
 - 8.2 第一步：逐 seed 语义 anchors
 - 8.3 第二步：局部 proposal hypergraph
 - 8.4 第三步：受约束功能匹配
 - 8.5 第四步：多 seed cycle/barycenter consistency
 - 8.6 第五步：ambiguity 与 refusal
 - 8.7 实用伪代码
 - 8.8 Exact cover 应放在哪里
- 9. 四类必须建立的实验性证据
 - 9.1 证据 A：语义选择性与同输入共同激活
 - 9.2 证据 B：跨 seed 替换与 reconstruction preservation
 - 9.3 证据 C：feature-vs-subspace 的公平因果比较
 - 9.4 证据 D：对 SAE 训练的反哺
- 10. 一套现实可运行的实验阶梯
 - 10.1 Stage 0：小型合成反例，不追求“大而全”
 - 10.2 Stage 1：一个模型/层的低成本 pilot
 - 10.3 Stage 2：confirmatory cross-model study
 - 10.4 Stage 3：distillation/retraining
- 11. 数据分割、统计与可复现性
 - 11.1 四分割
 - 11.2 独立单位是 seed 与 concept，不是 token pair
 - 11.3 Primary endpoint 与多重检验
 - 11.4 稀有概念
 - 11.5 自动解释的盲法
- 12. 论文主表应该长什么样
 - 12.1 主表 1：匹配是否真的非平凡
 - 12.2 主表 2：公平 feature-vs-group 因果比较
 - 12.3 主图 1：atom instability $\times$ group advantage
 - 12.4 主图 2：同一概念跨 seed dose-response
 - 12.5 主表 3：训练反哺 Pareto frontier
- 13. 必须做的消融与负对照
 - 13.1 匹配算法消融
 - 13.2 干预消融
 - 13.3 选择偏差负对照
 - 13.4 OOD 与方向符号

- 14. 预注册成功门与否认条件
 - 14.1 匹配成功门
 - 14.2 论文主张成立门
 - 14.3 明确否认
- 15. 建议的论文贡献层级
 - 15.1 最小可发表贡献
 - 15.2 强版本
 - 15.3 最强版本
 - 15.4 不应放在主标题的内容
- 16. 推荐执行顺序与 go/no-go 决策
 - Phase A: 2–3 周方法真实性检查
 - Phase B: 4–6 周完整测量论文
 - Phase C: 训练反哺
- 17. 当前最值得一试的具体实验
- 18. 已证明、经典、经验假设与新颖性候选清单
 - 18.1 已在上一轮完整推导中证明
 - 18.2 本报告使用但明确属于经典数学
 - 18.3 尚待实验的经验假设
 - 18.4 当前可主张的新颖性候选
- 19. 文献与本地原文审计
- 20. 最终研究判断
- 0. Status and claim discipline
- 1. Target
- 2. An identifiability boundary
- 3. Invariant observable
 - 3.1 Efficient kernel identity
- 4. Finest balanced partition
 - Definition 4.1 (balanced and partition-indecomposable pair)
 - Definition 4.2 (paired balanced partition)
 - THM-CBSM-001 (exact-cover characterization)
 - Corollary 4.3 (orthogonal block model)
- 5. Two complementary consistency coordinates
 - Definition 5.1 (balanced contribution consistency)
 - THM-CBSM-002 (sharp BCC characterization)
 - Definition 5.2 (projector subspace consistency)
 - THM-CBSM-003 (sharp PSC characterization)
 - Reporting rule
- 6. Gauge and split/merge invariance
 - THM-CBSM-004 (group gauge invariance)

- 7. Separation from one-to-one PW-MCC
 - THM-CBSM-005 (perfect block agreement with vanishing PW-MCC)
- 8. Finite-sample certificate
 - LEM-CBSM-006 (finite-family margin recovery)
 - THM-CBSM-007 (bounded finite-sample certificate)
- 9. Optimization form and algorithm
 - THM-CBSM-008 (positive-circuit representation)
- 10. Downstream intervention transfer
 - THM-CBSM-009 (causal interchangeability at a shared hook)
- 11. Falsifiers and boundary cases
- 12. Narrow candidate contribution
- Assurance status
- Round 0 issues found and fixed
 - FIX-001: support-minimal exact-cover statement
 - FIX-002: uniqueness in the orthogonal block corollary
 - FIX-003: zero-rank PSC
 - FIX-004: arbitrary group gauge versus SAE feasibility
 - FIX-005: audit centering in the finite-sample theorem
 - FIX-006: “Hadamard sequence”
- Current theorem-by-theorem audit
- Inequality audit
- Counterexample red team
- External-paper audit note: P23
- Verdict

PART I

目标导向的研究程序

从文献缺口、数学对象到算法、四类实验证据与训练反哺。

从跨 seed 子空间一致性到可训练的概念单元

一份面向顶会实证的数学、算法与实验研究蓝图

工作名称：Cross-Seed Concept Alignment and Distillation (CCAD)

数学核心：Contribution-Balanced Subspace Matching (CBSM)

版本日期：2026-08-27

状态：研究设计稿；数学中已证明、经典推论、经验假设与新颖性候选严格分开标记。


0. 结论先行

我们的目标不应被写成“提出一个更复杂的 subspace similarity metric”，而应被写成一个可被实验直接推翻的科学命题：

当同一个可解释概念因 SAE 的非唯一性而被不同 seed 分裂到不同数量、不同基底的 features 中时，**跨 seed 可复现的局部功能贡献子空间**，比任一单 feature 更接近该概念的正确干预单位；找到这些单元后，可以把它们蒸馏回更稳定、更紧凑、仍保持因果效应的 SAE 表示。

这一定义把工作拆成四个不可互相替代的阶段：

1. **Discover**：由自动解释、激活与几何信息提出局部概念组；
2. **Match**：在不同 seed 之间做局部 many-to-many matching；
3. **Validate**：用同输入激活、跨 seed 替换、ablation 和 steering 检验其功能等价性；
4. **Distill**：将经验证的概念单元反哺下一代 SAE 的训练。



当前最重要的判断是：**上一轮 CBSM 数学可以保留，但不能让 exact cover 主导现实算法**。真实语义会重叠、层级化、上下文依赖；主算法应输出局部、可重叠的概念超图，并能拒绝不充分的匹配。Exact cover 只保留为无重叠理想模型下的可识别性定理。

若要达到 ACL/ICLR/NeurIPS 水平，不能只证明 BCC 高，也不能只展示几个好看的自动解释。至少需要四类证据同时成立：

1. **语义证据**：匹配组确实选择同一概念，并排斥 hard negatives；
2. **功能替换证据**：用 seed B 的组替换 seed A 的组，保持重构与下游状态；
3. **因果证据**：在严格能量、大小、语义覆盖匹配下，组级 ablation/steering 比最佳单 feature 更一致；
4. **训练反哺证据**：蒸馏或正则化后的 SAE 在匹配 reconstruction、sparsity 与 alive-feature budget 下改善概念和因果指标。

前 3 项足以支撑“subspace is a better intervention unit”的论文；第 4 项会把论文从测量工作提升为训练方法工作，但也显著增加项目风险。

1. 我们究竟要证明什么

1.1 研究对象

在同一个基础模型、同一个 hook、相同训练数据与超参数下，独立训练 $S \geq 3$ 个 SAE。第 s 个 SAE 写为

$$h(x) = b^{(s)} + D^{(s)} z^{(s)}(x) + r^{(s)}(x),$$

其中 $h(x) \in R^d$ 是共享 hook activation, $D^{(s)} = [d_1^{(s)}, \dots, d_{m_s}^{(s)}]$, $z^{(s)}(x) \in R^{m_s}$, $r^{(s)}$ 是重构残差。

对 feature 子集 $I \subseteq [m_s]$, 定义它在输入 x 上的**动态解码贡献**

$$Y_I^{(s)}(x) = D_I^{(s)} z_I^{(s)}(x) = \sum_{i \in I} d_i^{(s)} z_i^{(s)}(x).$$

这是本项目最重要的观测量。仅比较 decoder span 会忽略输入依赖系数；仅比较 feature activation 会忽略 decoder 的尺度和方向；而 $Y_I^{(s)}(x)$ 是 SAE 真正加回 residual stream 的量。

1.2 “同一概念”不能只靠一句自然语言解释定义

一个候选概念 c 至少包含三个层面：

- **语义选择性**：在正例上响应，在相近但错误的 hard negatives 上不响应；
- **跨 seed 功能复现**：不同 seed 的组在同一输入上产生相近的 $Y(x)$ ；
- **因果效应**：对这些贡献做删除、替换或增强时，下游行为发生可复现的概念特异变化。

因此自动解释器只是 proposal generator，不是 ground truth。一个语言标签相同但功能不同的组不能算成功；一个贡献完全一致但无法赋予稳定语义的组只能叫“功能模块”，不能强称 monosemantic concept。

1.3 主假设

H1: 局部 many-to-many 可复现性。 对一部分概念 c , 存在小集合

$$I_c^{(1)}, I_c^{(2)}, \dots, I_c^{(S)}$$

使其在 held-out paired inputs 上具有高贡献一致性，而任意 one-to-one feature matching 都系统性较差。

H2: subspace intervention advantage. 对 H1 中的概念，在相同语义覆盖、干预能量、模型位置和选择预算下，matched group 的跨 seed ablation/steering 效应差异小于最佳单 feature。

H3: rank-adaptive concept unit. 某些概念的跨 seed 共识贡献近似 rank 1，适合蒸馏为单 feature；另一些概念具有不可忽略的 rank $r > 1$ ，应被保留为 concept block，而不是被强迫压成一个 atom。

H4：训练反哺。 使用经功能验证的 rank-adaptive concept targets 训练新 SAE，可以在相同 reconstruction、sparsity 与有效字典规模下，提高跨 seed 概念复现和干预可靠性。

H1-H3 是论文的最小完整故事。H4 是高价值扩展，不应在前三者尚未成立时消耗主要算力。

2. 文献线索：每篇工作给了什么，又没有给什么

以下判断来自逐篇正文与关键公式/图表阅读，而非摘要拼接。这里的“没有”只表示在本次检索到的公开版本中未发现，不能替代全球新颖性证明。

2.1 核心先例矩阵

工作	已建立的对象	对本项目最有价值之处	未覆盖的关键点
P18: Mechanistic Interpretability Should Prioritize Feature Consistency in SAEs	用 Hungarian assignment 和 decoder cosine 定义 one-to-one PW-MCC；理想 TopK 条件下讨论 permutation/scaling recovery	提供 atom-level 必须击败的 ACL 基线，并清楚区分 consistency 与 faithfulness/semantics	没有 unequal-cardinality 局部 group matching，也没有 feature-vs-subspace 因果比较
P04: Unstable Features, Reproducible Subspaces	unstable decoder atoms 可聚合成跨 seed 可复现的较低秩全局 span	直接说明 atom instability 不等于噪声；给出 basis ambiguity 的合成机制	全局稳定/不稳定集合，不自动切分局部语义块；projection explained variance 不检查 token-dependent contribution
P23: Subspace-Aware SAE	训练时用 block latents、group gating、核范数正则表达多维对象	说明“一个概念可能需要维数 > 1”；提供 projector、谱扰动和 block sparsity 语言	是 architecture-level block learning，不是 post-hoc 跨 seed 配对；部分 uniqueness 论证须谨慎使用
Sparse Autoencoders Do Not Find Canonical Units of Analysis	stitching 图与 MetaSAE 显示 SAE atoms 非 canonical，存在组合/分解关系	many-to-many grouping 的直接前驱；支持“不要迷信单 atom”	stitching 连通分量容易链式膨胀；没有 paired contribution certificate 和公平因果比较
MetaSAEs: Joint Training with a Decomposability Penalty	联合训练促使 latent 更 atomic	为蒸馏/训练阶段提供强基线	不是跨 seed 功能对齐，也不决定何时概念本来就应保持多维
Convergent Learning	早已提出神经表示的 one-to-one 与 many-to-many spectral matching	证明“many-to-many matching”本身绝不新	不针对 SAE 动态解码贡献、概念干预或训练反哺
Semantic Optimal Transport for SAE Feature Matching	用激活加权语义和 OT 匹配 features/circuits	很强的语义 proposal 和 transport baseline	语义/分布距离不等同于跨 seed group contribution 或因果可替换性
Evaluating SAE Interpretability with Concept Annotations	一个外部概念到 feature subset 的 FBMP；TAPAScore 做因果评估	概念监督、subset selection 和 causal scoring 的重要设计先例	是 many-to-one，不是两个 seed 两侧都未知的 many-to-many 对齐
Do SAEs Capture Concept Manifolds?	概念可能是 atom group 或局部几何对象；用 Ising/Louvain 发现结构	支持 overlapping/local manifold proposal，并提供失败模式	主要验证表征恢复，没有完成跨 seed matched causal comparison
SALVE	视觉模型中做 feature discovery、Grad-FAM 语义验证和 feature-guided intervention	完整的 discover-validate-control 模板；剂量-反应曲线；10 次 AE 初始化下曲线相似	各 seed 只选自己的 dominant feature；没有匹配其 basis/组，也没有 feature-vs-subspace 公平比较
Stable and Steerable SAEs	用权重正则提高 one-to-one stability，并报告 steering 改善	是必须对比的“让 single feature 更稳定”训练路线	改善与大量 latent 死亡/有效字典变小混杂；没有证明 subspace 是正确干预单位
SAE Subspace Guided Projections for Unlearning	按 forget/retain 激活评分选择大量 features，QR 得到 decoder subspace 后投影更新	明确否定“对 feature group/subspace 做 projection 是新方法”	目标是 topic-level unlearning；没有局部跨 seed concept matching 或单 feature 对照

2.2 SALVE 留下的最直接实验缺口

SALVE 在相同架构、损失和数据下训练 10 个不同初始化/数据顺序的 autoencoder。各自 latent basis 不同，但每个 SAE 所选 dominant class feature 的 suppression curve 近似相同。这是一个很接近我们问题的现象，却仍不能回答：

1. 不同 seed 的 dominant feature 是否真的编码同一局部概念；
2. 相似曲线是 feature 可复现，还是 base classifier 对任意相关扰动都稳健；
3. 一个 seed 的单 feature 是否对应另一个 seed 的多个 features；
4. matched group 是否比各 seed 自选的最佳单 feature 更可替换；
5. 曲线相似是否在 hard negatives、其他层、语言模型和非线性 downstream behavior 上成立。

因此 SALVE 最适合成为**实验模板与强先例**，而不是我们的结论。我们的版本必须把“各自选一个有效 feature”升级为“先盲法发现跨 seed 对应组，再在 held-out data 上做直接交换与因果曲线比较”。

2.3 Stable SAE 暴露的公平性陷阱

该工作中，在解释有效的 features 上，steering success 从 6.3% 提高到 13.0%；但 regularized TopK SAE 中大量 latents 不活跃，300 个抽样 features 中 115 个无法获得有效解释。因而不能简单得出“稳定性正则使 feature 更可 steer”。至少有三个混杂因素：

- 有效字典规模变小，相当于改变了模型容量；
- 只在具有有效解释的 feature 条件下比较会产生 selection bias；
- steering 只在特定 k 和有限 prompts 上测量。

所以我们的训练实验必须匹配：总字典宽度、alive features、平均 L_0 、重构误差、feature selection protocol 与 intervention norm。Stable SAE 是重要 baseline，也是一份实验设计警告。

2.4 其他紧邻工作对主张边界的影响

已有工作已经分别做过：多 feature steering、监督式稀疏 steering subspace、基于输出影响选择 SAE features、梯度增强 SAE、mediation subspace、belief geometry 和 concept-vector denoising。因此以下说法都不能作为创新主张：

- “首次用多个 SAE features 干预模型”；
- “首次用 SAE subspace steering/unlearning”；
- “首次 many-to-many matching”；
- “首次发现 feature group”；
- “首次提高 feature stability 或 steering”。

本项目可守住的窄而强的组合是：

自动、局部、跨 seed、两侧未知基数的概念组发现；以 paired dynamic contribution 为匹配核心；用 held-out 直接替换及公平 feature-vs-group causal comparison 验证；最后做 rank-adaptive 蒸馏。

截至 2026-08-27 的定向检索没有命中完整等价流程；这是“未命中先例”，不是“已证明首次”。论文提交前必须做标题/摘要/方法级新颖性复检与前后向引用追踪。

3. 方法总览：CCAD，而不是一个孤立 metric

3.1 输入与输出

输入：

- 同一 model hook 上训练的 $S \geq 3$ 个 SAE seeds；
- 相同输入位置上的 codes 与 decoder；
- 一组概念正例、hard negatives 和无关背景样本；
- 可选的自动解释、semantic OT、梯度或输出影响分数。

输出：

- 每个概念 c 在每个 seed 中的局部 feature set $I_c^{(s)}$ ；
- 一个跨 seed 共识贡献过程与其有效秩；
- 语义、替换、ablation、steering 四类证书；
- 对不充分证据的显式标签：unmatched、ambiguous、global-only 或 noncausal；
- 可供新 SAE 训练的 rank-1 feature target 或 rank- r block target。

3.2 三种不要混为一谈的“subspace intervention”

动态组贡献删除：

$$h_{-I}^{(s)}(x) = h(x) - Y_I^{(s)}(x).$$

这是 SAE 原生 intervention，系数随输入变化。

固定正交投影：若 $S_I = \text{span}(D_I)$ ，

$$h_{\perp I}(x) = (I - P_{S_I})h(x).$$

这会删除 hook state 中该 span 的所有成分，包括不由当前 SAE group 激活产生的成分。

固定方向 steering：

$$h_{+I}(x; \alpha) = h(x) + \alpha v_I,$$

其中 v_I 可为组均值、首主成分或监督方向。

三者因果问题不同。主实验应以动态 $Y_I(x)$ 的 ablation/swap 为基础，同时把 projection 和 fixed-vector steering 作为外部有效性检查。否则 SSPU 已经覆盖大量“subspace projection”空间。

3.3 为什么现实输出应是重叠超图

一个 feature 可能参与多个概念；一个概念可能在不同上下文使用不同局部 chart；概念之间也可能存在父子层级。因此主结构应是

$$G^{(s)} = \{I_c^{(s)} : c \in C_s\},$$

且允许 $I_c^{(s)} \cap I_{c'}^{(s)} \neq \emptyset$ 。

只有在明确假设“概念块互不重叠、完整覆盖所选 features”时，才求 exact cover。强迫全局 partition 会把真实复用误判成冲突，也会让算法退化为把整个 dictionary 匹配成一个无意义大块。

4. 数学核心一：动态贡献一致性

4.1 中心化过程与 Hilbert 空间

令 X 是 paired input 随机变量。定义

$$\Phi_I^{(s)}(X) = Y_I^{(s)}(X) - EY_I^{(s)}(X).$$

所有二阶可积的向量值过程构成 Hilbert 空间

$$H = L^2(\Omega; \mathbb{R}^d), \quad \langle U, V \rangle_H = E \langle U(X), V(X) \rangle_{\mathbb{R}^d}.$$

中心化一致性负责输入依赖变化；均值贡献

$$\mu_I^{(s)} = EY_I^{(s)}(X)$$

必须另行审计。只比较中心化过程会漏掉恒定偏移。

4.2 Balanced Contribution Consistency

定义

$$\text{BCC}(U, V) = \frac{2\langle U, V \rangle}{\|U\|^2 + \|V\|^2},$$

其中分母非零；双零情形单独标记为 inactive，而不是自动记为满分。

由恒等式

$$\|U - V\|^2 = \|U\|^2 + \|V\|^2 - 2\langle U, V \rangle$$

得到

$$\text{BCC}(U, V) = 1 - \frac{\|U - V\|^2}{\|U\|^2 + \|V\|^2}.$$

因此

$$-1 \leq \text{BCC}(U, V) \leq 1,$$

且当且仅当 $U = V$ 于 L^2 中成立时，

$$\text{BCC}(U, V) = 1.$$

这不是随意设计的相似度： $1 - \text{BCC}$ 正好是归一化的直接贡献交换误差。

4.3 高效 Gram 恒等式

对两个 seed 的中心化 code matrices Z_s, Z_t ，经验内积矩阵可写为

$$\hat{K}^{st} = ((D^{(s)})^T D^{(t)}) \odot \left(\frac{1}{n} Z_s^T Z_t \right),$$

其中 $\odot$ 是 Hadamard product。对 indicator vectors a_I, b_J ,

$$\langle \hat{\Phi}_I^{(s)}, \Phi_J^{(t)} \rangle = a_I^T \hat{K}^{st} b_J.$$

于是候选组评分无需重复构造 $n \times d$ 的贡献张量，能够在局部邻域中用二次型快速评估。

4.4 Projector Subspace Consistency

令 P_I, Q_J 分别为两个 decoder spans 的正交投影，秩为 r_I, r_J 。定义

$$\text{PSC}(I, J) = \frac{2 \operatorname{tr}(P_I Q_J)}{r_I + r_J} = 1 - \frac{\|P_I - Q_J\|_F^2}{r_I + r_J}.$$

PSC 与 BCC 不能互相替代：

- PSC 高、BCC 低：两个组处于同一几何 span，却在输入上做不同计算；
- BCC 高、PSC 低：总贡献一致，但某组含有未使用、冗余或抵消方向；
- 两者都高：既具有相近动态功能，也没有明显几何膨胀。

PSC 应是诊断和正则项，不应成为唯一主目标。

4.5 抵消审计

定义 feature participation energy

$$A_I^{(s)}(x) = \sum_{i \in I} |z_i^{(s)}(x)| \|d_i^{(s)}\|_2,$$

net contribution magnitude

$$R_I^{(s)}(x) = \|Y_I^{(s)}(x)\|_2,$$

以及 cancellation index

$$C_I^{(s)} = 1 - \frac{ER_I^{(s)}}{EA_I^{(s)} + \varepsilon}.$$

若 BCC 很高但 C_I 接近 1，则“匹配”可能靠大项相互抵消实现。此类组不能进入因果结论，除非消融实验明确说明抵消本身具有功能意义。

5. 数学核心二：为何 one-to-one 可以任意差

5.1 Hadamard 分离定理（已证明）

取存在实 Hadamard matrix 的 $q = 2^k$ ，令

$$Q = \frac{1}{\sqrt{q}} H_q,$$

则 Q 正交且每个元素绝对值均为 $q^{-1/2}$ 。设 seed A 使用标准基，seed B 使用旋转基 Q ，并用 signed-ReLU 成对表示正负坐标，使两侧完整组对每个输入产生完全相同的重构贡献。

那么组级指标满足

$$\text{BCC} = 1, \quad \text{PSC} = 1,$$

但任意 A atom 与任意 B atom 的绝对 decoder cosine 都是

$$q^{-1/2}.$$

故 Hungarian one-to-one PW-MCC 也为

$$\text{PW-MCC} = q^{-1/2} \rightarrow 0.$$

解释。 这给出严格存在性证明：即使两个 seed 在组功能与 span 上完全一致，atom-level consistency 仍可趋近于零。因此“PW-MCC 低”不能推出“没有可复现概念”。

边界。 这不是现实 SAE 一定出现此现象的证明。真实贡献必须由实验确认；Hadamard family 只是证明 one-to-one 假设在数学上并不完备。

5.2 Gauge 与 split/merge 不变性（已证明）

若一个组内做可逆坐标变换

$$D'_I = D_I R, \quad z'_I = R^{-1} z_I,$$

则

$$D'_I z'_I = D_I z_I = Y_I.$$

所以贡献过程天然消除了组内 basis ambiguity。相同结论覆盖一个 feature 被拆成多个相加 feature，或多个 feature 被合并的理想情况。PSC 只有在 decoder ranges 相同时才保持 1，因此它能发现“功能相同但 span 膨胀”。

6. 数学核心三：匹配与干预之间的桥

6.1 直接跨 seed 替换

在同一 hook 上，用 seed B 的组贡献替换 seed A 的组贡献：

$$\hat{h}_{A \leftarrow B}(x) = \hat{h}_A(x) - Y_I^{(A)}(x) + Y_I^{(B)}(x).$$

定义中心化 normalized swap error

$$\text{SE}_{\text{ctr}}(I, J) = \frac{E \left\| \phi_I^{(A)} - \phi_J^{(B)} \right\|_2^2}{E \left\| \phi_I^{(A)} \right\|_2^2 + E \left\| \phi_J^{(B)} \right\|_2^2},$$

并把均值偏差

$$\text{ME}(I, J) = \left\| \mu_I^{(A)} - \mu_J^{(B)} \right\|_2^2$$

作为单独项报告。此时严格有

$$\text{SE}_{\text{ctr}} = 1 - \text{BCC}.$$

因此不能把“优化 BCC”与“贡献向量 swap error 变小”当成两项独立实验证据。真正独立的证据必须来自 downstream reconstruction/state/logits、未用于匹配的概念判别器和因果行为。

6.2 同 hook 因果可交换性（已证明）

设 $F: R^d \rightarrow Y$ 是 hook 之后的确定性模型。若对几乎处处的输入

$$Y_I^{(A)}(x) = Y_J^{(B)}(x),$$

则

$$F(h(x) - Y_I^{(A)}(x)) = F(h(x) - Y_J^{(B)}(x)).$$

证明只有一步：两个 intervention 后送入 F 的向量相等。因此这不是强因果识别理论，而是一个精确的 same-hook substitution lemma。

若 F 关于选定输出范数是 L -Lipschitz，则

$$\|F(h - Y_I^{(A)}) - F(h - Y_J^{(B)})\| \leq L \|Y_I^{(A)} - Y_J^{(B)}\|.$$

于是

$$E \|\Delta_I^{(A)} - \Delta_J^{(B)}\|^2 \leq L^2 E \|Y_I^{(A)} - Y_J^{(B)}\|^2,$$

其中

$$\Delta_I^{(s)}(x) = F(h(x)) - F(h(x) - Y_I^{(s)}(x)).$$

这给出从匹配误差到 downstream effect 差异的理论桥，但真实 Transformer 的全局 L 往往过松，所以它只支持趋势，不替代实测。

6.3 多 seed 共识恒等式（经典 Hilbert-space ANOVA）

对同一候选概念的 S 个贡献过程 $Y_1, \dots, Y_S \in H$ ，定义重心

$$\bar{Y} = \frac{1}{S} \sum_{s=1}^S Y_s.$$

则

$$\sum_{s=1}^S \|Y_s - \bar{Y}\|^2 = \frac{1}{S} \sum_{1 \leq s < t \leq S} \|Y_s - Y_t\|^2.$$

证明。 展开左式：

$$\sum_s \|Y_s\|^2 - S \|\bar{Y}\|^2.$$

展开右式并整理得到同一表达式。

用途。 我们不必把一个 seed 选作永恒 reference。多 seed barycenter 是平方误差意义下的唯一最优共识，并把所有 pairwise inconsistency 汇总成一个量。若 F 为 L -Lipschitz，则对应 effect 的跨 seed 离差也由该量控制：

$$\sum_s \|\Delta_s - \bar{\Delta}\|^2 \leq L^2 \sum_s \|Y_s - \bar{Y}\|^2$$

在逐点使用共同 baseline 且 F 满足相应 Lipschitz 条件时成立。

6.4 不能保证“总有有意义的局部解”

整个 dictionary 的重构都接近 h ，所以取所有 features 往往得到一个平凡全局匹配。但这并不意味着存在小而纯的局部概念组。正确算法必须允许：

- 只有 whole-dictionary match；
- 多个局部组同样解释数据；
- 某 seed 缺失相应概念；
- 匹配只在特定输入区域成立；
- 匹配可预测重构，却不能预测语义干预。

这些不是算法“失败后要隐藏”的情况，而是关于 SAE 可识别性的科学结果。

7. 数学核心四：何时蒸馏为单 feature，何时保留 block

7.1 共识贡献矩阵

对概念 c 的 audit inputs $x_1, \dots, x_n$ ，把多 seed barycenter contribution 排成

$$M_c = \begin{bmatrix} \bar{Y}_c(x_1)^T \\ \vdots \\ \bar{Y}_c(x_n)^T \end{bmatrix} \in R^{n \times d}.$$

奇异值为

$$\sigma_1 \geq \sigma_2 \geq \dots \geq 0.$$

7.2 Rank-adaptive 蒸馏判据（Eckart-Young 的直接应用）

所有 rank- r 矩阵中， M_c 的截断 SVD 给出最小 Frobenius error：

$$\min_{\text{rank}(B) \leq r} \|M_c - B\|_F^2 = \sum_{k > r} \sigma_k^2.$$

因此定义解释方差

$$\text{EV}_c(r) = 1 - \frac{\sum_{k > r} \sigma_k^2}{\sum_k \sigma_k^2}.$$

若 $\text{EV}_c(1)$ 在 held-out data 上已高于预注册阈值，而且 rank-1 steering 保持完整组效应，则将概念蒸馏为一个 feature 是合理的。若谱尾显著，任何单方向都存在不可消除的平方误差下界；此时应训练一个 rank- r concept block。

这个结论来自经典低秩逼近，不是新的纯数学定理。它的论文价值在于给出一个**数据驱动、可审计的 atom-vs-block 决策规则**，避免先验地把 monosemanticity 等同于“一条 decoder direction”。

7.3 “monosemantic”应描述语义，而非维数

一个单一概念可以有多维内部自由度，例如语气强度、位置、实体实例或上下文 chart；反之一个 rank-1 direction 也可能 polysemantic。因此建议区分：

- **semantic purity**：响应是否只对应一个可定义概念；
- **geometric rank**：实现该概念所需的有效维数；

- **causal specificity**: 干预是否只改变目标行为；
- **cross-seed reproducibility**: 该功能单元是否在不同训练重复中复现。

论文最好主张 “reproducible concept unit”，而不是轻率主张所有成功组都 “真正 monosemantic”。

8. 候选发现与 many-to-many 匹配算法

8.1 为什么不能对所有 subsets 暴力搜索

对 m 个 features 的全部子集搜索是 2^m 级别；两侧联合搜索更糟。算法必须先产生高召回的局部邻域，再做受约束 subset matching。语义、激活与几何算法适合作为 proposals，但不能直接充当最终功能证书。

8.2 第一步：逐 seed 语义 anchors

对每个 seed 独立执行：

1. 自动解释 feature 的高激活文本片段；
2. 用正例、hard negatives、无关 negatives 测量 activation AUPRC；
3. 计算 decoder/output logit/gradient 或 causal mediation 相关分数；
4. 对语义相近 features 建立候选概念 anchors；
5. 保留多个不确定解释，不做过早 hard assignment。

为了避免标签泄漏，自动解释模型只能看到 discovery split；最终 audit prompts 和人工评价必须盲化。

8.3 第二步：局部 proposal hypergraph

对每个 anchor i ，合并以下邻居：

- cross-seed paired activation/contribution affinity；
- decoder cosine 或 P18 Hungarian 邻居；
- semantic OT 邻居；
- within-seed conditional dependence、Ising 或 Louvain community；
- 输出影响、梯度或 mediation 邻居；
- stitching/MetaSAE 分解关系。

proposal 的目标是高召回，允许包含错误项。最终组大小限制为 $1 \leq |I|, |J| \leq g_{\max}$ ，并保留 overlap。

8.4 第三步：受约束功能匹配

对每个候选组 I, J ，使用 discovery split 最小化

$$L(I, J) = \frac{E \left\| \Phi_I^{(A)} - \Phi_J^{(B)} \right\|^2}{E \left\| \Phi_I^{(A)} \right\|^2 + E \left\| \Phi_J^{(B)} \right\|^2 + \varepsilon} + \lambda_\mu \frac{\left\| \mu_I^{(A)} - \mu_J^{(B)} \right\|^2}{\left\| \mu_I^{(A)} \right\|^2 + \left\| \mu_J^{(B)} \right\|^2 + \varepsilon} + \lambda_p (1 - \text{PSC}(I, J)) + \lambda_c (C_I + C_J) + \lambda_g (|I| + |J|) + \lambda_u U(I, J),$$

其中 U 是语义不纯、occupancy mismatch 或 unmatched energy 惩罚。为了不把结论写进 objective，最终优越性必须在未参与优化的 downstream endpoints 上验证。

8.5 第四步：多 seed cycle/barycenter consistency

仅在 A-B 上匹配可能过拟合偶然相关。对 $S \geq 3$ 个 seeds，要求每个候选概念的 group-to-barycenter error 较小：

$$V_c = \frac{\sum_s \|Y_c^{(s)} - \bar{Y}_c\|_H^2}{\sum_s \|Y_c^{(s)}\|_H^2 + \varepsilon}.$$

采用 leave-one-seed-out：用 $S - 1$ 个 seeds 建立共识，再检验第 S 个 seed 是否能被局部搜索捕获。只有 pairwise 高分但无法接入多 seed 共识的匹配，标记为 unstable pair，不进入核心结果。

8.6 第五步：ambiguity 与 refusal

若多个候选组在 calibration uncertainty 内不可区分，输出 ambiguity set

$$A_c^{(s)} = \{I_{c,1}^{(s)}, \dots, I_{c,k}^{(s)}\},$$

而不是任意挑一个。若只有大组或全字典匹配通过，输出 global-only。若没有组通过，输出 unmatched。拒绝率应作为主要结果报告，因为一个永远返回答案的 matcher 很容易靠扩大 subspace 获得虚假的高一致性。

8.7 实用伪代码

```

INPUT: S SAE seeds, paired activations, semantic examples, budgets g_max and K

for each seed s:
    auto-interpret features on discovery split
    score semantic selectivity with positives and hard negatives
    build overlapping local candidate groups

for each concept anchor c:
    collect cross-seed proposal neighborhoods using
        semantic OT + contribution affinity + decoder geometry
        + within-seed dependence + optional gradient/output scores
    enumerate or beam-search small subset pairs up to g_max
    rank candidates by contribution loss, mean loss, PSC,
        cancellation, group size and semantic impurity
    retain every candidate inside the calibration tie band
    construct a multi-seed barycenter and run leave-one-seed-out recovery
    if no local candidate passes: return UNMATCHED or GLOBAL-ONLY
    if multiple candidates remain indistinguishable: return AMBIGUOUS
    otherwise: freeze the matched groups

on untouched audit data:
    evaluate semantic selectivity
    perform direct swap and reconstruction/state preservation
    run energy-matched ablation and steering dose-response
    compare against best single feature and all group baselines

if a group is validated:
    estimate consensus singular spectrum
    distill to rank 1 only when held-out spectral and causal tests permit
    otherwise distill to a rank-r concept block

```

8.8 Exact cover 应放在哪里

在理想无重叠模型中，定义 support-minimal balanced pairs，所有 finest balanced partitions 正好对应这些 hyperedges 的 maximum-cardinality exact covers。该结论和正 0-1 circuit 表示仍是正确而有价值的数学附录：它给出什么时候“最细分解”可被组合优化刻画。

但现实主算法不应声称 concepts 构成 partition。Exact cover 更适合：

- synthetic identifiability test;
- 对互斥概念簇的特殊分析;

- 枚举多解并证明不可识别；
- 小邻域中的精确算法对照。

9. 四类必须建立的实验性证据

9.1 证据 A：语义选择性与同输入共同激活

问题

两个 matched groups 是否在相同输入位置表达同一概念，而不仅仅是位于相似 decoder span？

指标

组活动不只使用 $\sum_i z_i$ ，因为正负或尺度可能抵消。至少报告：

$$G_I^{\text{part}}(x) = \sum_{i \in I} |z_i(x)| \|d_i\|,$$

$$G_I^{\text{net}}(x) = \|Y_I(x)\|_2,$$

以及概念判别 AUPRC、AUROC、positive-vs-hard-negative effect size。跨 seed 同输入一致性可用 rank correlation、binary co-activation Jaccard 和 conditional calibration curve。

公平对照

- P18 matched single feature；
- 每侧语义分数最佳的 single feature；
- 相同 feature 数、occupancy 和总活动能量的随机组；
- semantic OT group；
- stitching/LI15/Concept-Manifold group；
- P04 global unstable subspace。

成功条件

proposed group 在 held-out concepts 与 hard negatives 上同时提高跨 seed agreement 和 semantic selectivity；只提高正例激活而增加 hard-negative response 不算成功。

关键失败模式

- 高频 token、position 或文体造成伪共同激活；
- 自动解释器用同一词给不同功能贴标签；
- group size 越大越容易激活；
- 概念频率差异造成 AUPRC 不可直接比较。

因此所有阈值在 calibration split 固定，评价用 document-level bootstrap，并对 group size、频率和 activation mass 配平。

9.2 证据 B：跨 seed 替换与 reconstruction preservation

最强检验：无需拟合的 direct swap

在同一个真实 hook activation 上，比较

$$\hat{h}_A = h - r_A,$$

$$\hat{h}_{A \leftarrow B} = \hat{h}_A - Y_I^{(A)} + Y_J^{(B)}.$$

测量：

- hook reconstruction error;
- 下一 residual checkpoint 的 L_2/cosine ;
- next-token logits KL/Jensen–Shannon divergence;
- target concept score 和非目标能力变化。

三层 transfer 难度

1. **Direct**: 不拟合任何 map, 直接交换 Y ; 主结果应优先使用;
2. **Scale-calibrated**: 只在 calibration split 拟合一个标量 α^* ;
3. **Relaxed stitching**: 拟合正交或低秩 map; 只能作为诊断, 不能与 direct 方法混报。

若只有自由 linear map 后才成功, 说明找到的是可对齐表示, 不是 SAE 原生可交换概念单元。

防止循环论证

BCC 与 raw contribution swap error 代数等价, 所以不能把二者当两项胜利。主要 endpoint 必须是未用于优化的 downstream state/logit/behavior; 匹配只在 discovery/calibration data 上完成。

成功条件

在相同 matched contribution energy 下, CCAD 的 held-out downstream swap error 显著低于所有 single-feature 与 group baselines, 并且不存在明显 unmatched-energy 转移。

9.3 证据 C: feature-vs-subspace 的公平因果比较

这是整篇论文最关键、也是现有文献没有完成的实验。

Ablation

对 seed s 和组 I ,

$$h_{-I}^{(s)}(x) = h(x) - Y_I^{(s)}(x).$$

对输出统计 T , 定义

$$\text{ATE}_I^{(s)} = E[T(F(h)) - T(F(h - Y_I^{(s)}))].$$

跨 seed effect inconsistency 可写为

$$\text{CErr}_c = \frac{1}{S} \sum_s \left(\text{ATE}_{I_c}^{(s)} - \bar{\text{ATE}}_c \right)^2.$$

还应报告 effect curve, 而不是只报告一个平均数。

Steering dose-response

选择校准后的方向或动态贡献模板, 令

$$\Gamma_I^{(s)}(\alpha) = E\left[T\left(F(h + \alpha v_I^{(s)})\right)\right], \quad \alpha \in A.$$

跨 seed 曲线距离

$$D_I(I, J) = \int_A \left(\Gamma_I^{(A)}(\alpha) - \Gamma_J^{(B)}(\alpha) \right)^2 w(\alpha) d\alpha.$$

报告 target gain、fluency/perplexity、KL、off-target concept effects、toxicity/safety 等适用副作用，不能只展示目标 score。

公平性的五个必要匹配

1. **能量匹配**：单 feature 与 group 的 RMS intervention norm 相同；
2. **语义覆盖匹配**：在 calibration split 上正例 recall 相同，避免 group 因“覆盖更多”天然占优；
3. **选择预算匹配**：best single feature 允许从同一候选邻域中调参选择；
4. **数据分割匹配**：selection 和 evaluation 完全分离；
5. **模型预算匹配**：同一 hook、同一 base model、同一 SAE quality 范围。

核心 baseline 层级

必须有：

- P18 PW-MCC pair；
- best semantic single feature；
- best functional single feature（用 calibration output-effect 选择）；
- random size/occupancy/energy-matched groups；
- P04 global subspace；
- stitching/MetaSAE group；
- Li15 spectral many-to-many；
- semantic OT group；
- proposed CCAD group。

资源允许时加入：FBMP、Concept-Manifold/Louvain、supervised SAE subspace、output-score feature selection、gradient SAE、mediation subspace。

真正支持论文的 interaction

最有解释力的结果不是“group 永远赢”，而是

group advantage 随 atom instability 或 group effective rank 增大而增大。

即在 P04 式 unstable region 中 group 明显优于 single feature，而在高度稳定、近 rank-1 concepts 中二者接近。这一 interaction 既符合理论，也能排除“组只是更大所以更强”的平庸解释。

9.4 证据 D：对 SAE 训练的反哺

两条训练路线

路线 1：rank-1 concept distillation。对 $EV_c(1)$ 高且因果曲线由单方向保持的概念，加入一个 target atom，使其贡献逼近多 seed barycenter：

$$L_{\text{distill}, c} = E \left\| d_c z_c(x) - \bar{Y}_c(x) \right\|_2^2.$$

路线 2：rank- r block distillation。对谱尾不可忽略的概念，学习 block $D_c z_c(x)$ ：

$$L_{\text{block},c} = E \left\| D_c z_c(x) - \bar{Y}_c(x) \right\|_2^2 + \lambda_{\text{rank}} \Omega(D_c, z_c).$$

总体目标可写成

$$L = L_{\text{SAE}} + \lambda_d \sum_{c \in C_{\text{verified}}} w_c L_{\text{distill} / \text{block},c} + \lambda_x L_{\text{exclusivity}} + \lambda_s L_{\text{stability}}.$$

w_c 应依据证书置信度，而不是 auto-interp 主观分数。

训练成功不能只看单项指标

新 SAE 必须与以下预算匹配：

- reconstruction loss;
- 平均 L_0 或激活密度;
- total width 与 alive-feature count;
- dead latent rate; -训练 token 与计算量;
- downstream perplexity/utility。

然后比较：

- P18 PW-MCC;
- CCAD group consistency;
- concept purity/coverage;
- feature 或 block rank;
- direct swap error;
- ablation/steering reproducibility;
- off-target effects。

只有在这些约束下出现 Pareto 改善，才能说训练真正受益，而不是通过缩小有效字典、降低稀疏性或牺牲 reconstruction 换取稳定性。

训练 baselines

- vanilla SAE;
- Stable and Steerable SAE 的 regularization，严格匹配 alive count;
- MetaSAE/joint decomposability;
- Subspace-Aware SAE/SASA;
- Universal SAE 或 joint multi-model/seed training;
- gradient/end-to-end SAE（若下游因果性是主要目标）。

10. 一套现实可运行的实验阶梯

10.1 Stage 0：小型合成反例，不追求“大而全”

先跑四个能直接杀死方法的 family：

1. **Hadamard rotation**：组完全一致、atom match 趋零；
2. **split/merge**：两侧 group cardinality 不同；
3. **co-occurrence confounder**：不同概念总是共同出现，测试错误合并；

4. whole-dictionary-only: 不存在局部解，测试拒绝能力。

核心指标：planted group recovery、false merge、ambiguity/refusal accuracy、运行时间。只有这四类通过，才值得上真实 LLM。

10.2 Stage 1: 一个模型/层的低成本 pilot

建议：

- 一个开放权重小模型；
- 一个 residual-stream hook；
- 同一 SAE 配置的 6 个 seeds；
- 固定一个 width/sparsity；
- 50–100 个包含 hard negatives 的概念；
- $g_{\max} \in \{2, 4, 6\}$ ；
- document-level 四分割。

Pilot 只回答三件事：

1. 是否发现非平凡、小而纯的 local groups；
2. 它们是否在 leave-one-seed-out 中复现；
3. 它们是否在 energy-matched ablation 上击败 best single feature。

如果第 3 项不成立，不进入大规模训练。

10.3 Stage 2: confirmatory cross-model study

最低配置：

- 2 个 model families；
- 3 个 layers/hook positions；
- 2 个 dictionary widths 或 sparsity regimes；
- 每个关键配置 6–8 个 seeds；
- 至少一个自然语言生成 steering task、一个分类/事实概念 task；
- 对关键概念做人类盲评。

这里不需要把所有组合做成完全笛卡尔积。先由 pilot 固定方法，再在预注册的代表性配置上做 confirmatory test。

10.4 Stage 3: distillation/retraining

只选择 Stage 2 中通过全部证书的 concepts。比较 rank-1 与 rank-adaptive block distillation，并设置：

- 从零训练；
- warm-start；
- 不使用 concept target 的同预算 control；
- Stable SAE 与 MetaSAE/SASA baseline。

训练后的 evaluation concepts 分为 seen、semantic paraphrase、compositional shift 和完全 held-out concepts，以判断是概念学习还是 target memorization。

11. 数据分割、统计与可复现性

11.1 四分割

用

(dataset id, document id, token offset)

的固定 hash 分配：

- 10% mean split：估计 $\mu_l^{(s)}$ ；
- 40% discovery split：auto-interp、proposal 与候选搜索；
- 20% calibration split：阈值、 $g_{\max}$ 、intervention norm 和选择规则；
- 30% audit split：所有最终数值和置信区间。

同一 document 不能跨 split，防止相邻 token 泄漏。打开 audit split 前冻结 candidate family、超参数和 primary endpoint。

11.2 独立单位是 seed 与 concept，不是 token pair

数百万 tokens 不等于数百万独立实验。推荐 crossed mixed-effects 模型：

$$y_{stc} = \beta_0 + \beta_1 \text{Method} + \beta_2 \log \text{Freq}_c + \beta_3 \text{GroupSize}_{stc} + u_s + u_t + v_c + \epsilon_{stc},$$

其中 u_s, u_t 是 seed effects， v_c 是 concept effect。实际实现可使用多成员随机效应或对 unordered seed pair 建随机截距。置信区间至少做 document-within-concept bootstrap 和 seed-level bootstrap；token-level CI 不能作为主证据。

11.3 Primary endpoint 与多重检验

建议唯一 primary endpoint 为：

在预注册的 unstable/high-rank concept stratum 中，CCAD group 相对 calibration-selected best single feature 的 held-out cross-seed causal curve error 降低量。

direct swap、semantic AUPRC、reconstruction preservation、off-target effect 和 distillation gain 为 secondary endpoints。对 secondary families 使用 Holm 或 Benjamini–Hochberg；不要挑选最有利的 concept 单独报显著性。

11.4 稀有概念

对 activity weights w_t ，报告

$$n_{\text{eff}} = \frac{(\sum_t w_t)^2}{\sum_t w_t^2}.$$

低 n_{eff} group 不做强结论。rare-feature 结果可作为单独 stratum，而不是与高频概念混合平均。

11.5 自动解释的盲法

- 解释器只看 discovery examples；
- 生成概念正/负例时不暴露 method identity；
- 两名人类评审独立判断 label coherence 和 intervention outputs；

- 冲突由第三人裁决；
- 报告 inter-rater agreement；
- 自动 judge 模型与 SAE/base model 尽可能不同，避免同源偏差。

12. 论文主表应该长什么样

12.1 主表 1：匹配是否真的非平凡

每个方法报告：

- matched concept coverage；
- median group sizes $|I| \leftrightarrow |J|$ ；
- refusal/ambiguity rate；
- unmatched contribution energy；
- semantic AUPRC；
- BCC 与 PSC；
- cancellation index；
- leave-one-seed-out recovery。

这张表防止方法用更大的组或更低的 coverage 换取高一致性。

12.2 主表 2：公平 feature-vs-group 因果比较

在 energy/coverage-matched 条件下报告：

- ablation effect variance across seeds；
- steering curve distance；
- target effect；
- off-target effect；
- perplexity/KL degradation；
- 直接 swap 后 downstream state/logit error。

最关键的行是 `best functional single feature`，不是随机 single feature。若 proposed group 不能击败这个强 baseline，就不能声称 subspace 是更正确的 intervention unit。

12.3 主图 1：atom instability $\times$ group advantage

横轴为 P04 式 atom stability 或 PW-MCC，纵轴为

$$\Delta_{\text{group}} = \text{CErr}_{\text{single}} - \text{CErr}_{\text{group}} .$$

颜色表示 consensus effective rank。预期：低 atom stability、高 rank 区域的 group advantage 最大；rank-1 稳定区接近零。

12.4 主图 2：同一概念跨 seed dose-response

每个 seed 一条 ablation/steering curve，分别画 best single 与 matched group。需要展示均值以外的 seed 离散度和 off-target 曲线。SALVE 的视觉呈现可以借鉴，但我们的 group 是先经跨 seed matching 冻结的。

12.5 主表 3：训练反哺 Pareto frontier

横向比较 vanilla、Stable SAE、MetaSAE/SASA、rank-1 distill 和 rank-adaptive distill：

- reconstruction；
- L_0 ；
- alive features；
- concept coverage/purity；
- PW-MCC；
- group consistency；
- causal reproducibility。

任何只在未匹配 SAE quality 下取胜的结果都不应进入主结论。

13. 必须做的消融与负对照

13.1 匹配算法消融

- 只用 decoder cosine；
- 只用 activation correlation；
- 只用 semantic OT；
- contribution kernel without PSC；
- contribution kernel without semantic constraints；
- 不做 cancellation audit；
- pairwise only vs multi-seed barycenter；
- 强制唯一 match vs ambiguity/refusal；
- greedy/beam search vs 小邻域 exact solver。

13.2 干预消融

- dynamic contribution ablation；
- fixed projector ablation；
- fixed mean/PCA direction steering；
- direct swap；
- scalar calibrated swap；
- learned stitching map。

这会告诉我们收益来自“正确的动态 concept contribution”，还是仅来自“更大的线性 span”。

13.3 选择偏差负对照

- 标签打乱；
- seed 配对打乱；
- concept positives 与频率匹配的 hard negatives 互换；
- 对同一 seed 做伪跨 seed match；
- 随机等大小/等能量 group；
- 用 audit split 选 feature 的故意泄漏上界，仅作为 sanity check，不可与正式结果混用。

13.4 OOD 与方向符号

已有 steering 工作提示，重构 steering vector 可能因负投影或 OOD 激活而失去效应。因此检查：

- 正/负 steering 分开；
- activation percentile 内与外分开；
- natural activation templates 与常数方向分开；
- prompt distribution shift；
- layer shift；
- generated continuation drift。

14. 预注册成功门与否证条件

14.1 匹配成功门

一个 concept match 进入 causal audit 前必须同时满足：

1. local group size 不超过 $g_{\max}$ ；
2. audit BCC/mean error 达标；
3. PSC 不显示严重 span 膨胀；
4. cancellation index 低于阈值；
5. semantic hard-negative selectivity 达标；
6. 至少 3 个 seeds 接入共识；
7. leave-one-seed-out 可恢复；
8. ambiguity 被明确报告。

14.2 论文主张成立门

只有以下全部成立才支持 “subspace is the better intervention unit”：

1. proposed groups 在 held-out causal endpoint 上击败 best functional single feature；
2. 优势在多个 seeds 和 concepts 上存在，而非由少数 token 驱动；
3. group size、semantic coverage、intervention energy 与 SAE quality 已配平；
4. 优势在 unstable/high-rank stratum 更强；
5. off-target damage 不增加；
6. global-only 与 unmatched cases 被诚实拒绝。

14.3 明确否证

出现下列任一情形，应收缩或拒绝主张：

- 只在 BCC 或等价的 raw swap metric 上提高；
- group 优势在匹配能量/coverage 后消失；
- best single feature 与 group 一样好；
- 只有 whole-dictionary group 通过；
- 匹配不能推广到未参与发现的 seed；
- 自动解释相同但 hard-negative 或因果方向不同；

- distillation 改善来自 alive-feature collapse 或 reconstruction 牺牲；
- 多种不可区分 covers 被隐瞒为唯一答案。

负结果仍然有价值：若稳定 rank-1 concepts 中 single feature 足够，而 unstable high-rank concepts 中 group 才必要，这个边界本身就是清晰结论。

15. 建议的论文贡献层级

15.1 最小可发表贡献

1. 定义跨 seed 的 local many-to-many dynamic-contribution matching 问题；
2. 提出 CCAD/CBSM 算法并允许 overlap、ambiguity 与 refusal；
3. 给出 gauge/split-merge invariance、Hadamard separation、same-hook intervention transfer；
4. 在严格公平实验中证明 group 比 best single feature 更跨 seed 因果一致。

15.2 强版本

在最小版本上加入：

- 多 seed barycenter/cycle consistency；
- rank-adaptive atom-vs-block 决策；
- 两模型多层 confirmatory study；
- 概念 hard-negative 与人类盲评；
- 可复现的开源 benchmark。

15.3 最强版本

再加入 rank-adaptive distillation，使验证过的 group 反哺训练，并展示匹配 SAE-quality 下的 Pareto 改善。

15.4 不应放在主标题的内容

- exact cover 或 oriented matroid 本身；
- 单独的 BCC metric；
- “first many-to-many”；
- “first subspace intervention”；
- 仅仅提升 PW-MCC；
- 没有因果比较的自动解释案例。

数学应该解释为什么方法需要 group、为什么功能匹配与干预相连、什么时候能压缩为单 feature，而不是为了显得复杂。

16. 推荐执行顺序与 go/no-go 决策

Phase A：2–3 周方法真实性检查

1. 实现四个合成 family；
2. 实现 P18、P04、stitching、spectral 和 random baselines；

3. 实现局部 contribution matcher 与 refusal;
4. 在一个 hook、6 seeds、少量 concepts 上跑 direct swap 和 energy-matched ablation。

Go 条件：至少存在一批不平凡 matched groups，在 held-out causal error 上稳定击败 calibration-selected best single feature。

Phase B：4–6 周完整测量论文

1. 固定 primary endpoint;
2. 扩到两个模型家族与多层;
3. 加入 semantic hard negatives、盲评和 dose-response;
4. 估计 group advantage 与 atom stability/effective rank 的 interaction;
5. 做新颖性与引用链复检。

Go 条件：主效应与 interaction 都跨配置存在，且不靠 group size/energy 或 coverage 混杂。

Phase C：训练反哺

1. 从验证组构建 barycenter targets;
2. 先做 rank-1 vs rank-adaptive 小规模蒸馏;
3. 再与 Stable SAE、MetaSAE/SASA 比;
4. 最后才扩大模型与 seed 数。

No-go 条件：若训练优势只来自更少 alive features 或 reconstruction 退化，则停止训练主张，但保留测量论文。

17. 当前最值得一试的具体实验

若现在只能选一个实验，我建议做：

P04 instability-stratified, energy-matched feature-vs-group causal interchangeability test。

具体流程：

1. 在同一 hook 训练 6 个 SAE seeds;
2. 用 P04 指标把 anchors 分为 stable 与 unstable;
3. 对每个 anchor 用 auto-interp + contribution affinity 构造大小不超过 4 的跨 seed groups;
4. 在 calibration data 上分别选 best single feature 与 best group;
5. 在 audit data 上做 direct swap、dynamic ablation 和 7 点 steering curve;
6. 对单 feature 与 group 做相同 RMS intervention norm 和相同 positive recall;
7. 检验 method $\times$ instability 与 method $\times$ effective-rank interaction;
8. 同时报告 semantic hard negatives 与 off-target damage。

这一个实验能同时连接 P18、P04、SALVE、Stable SAE 和我们的数学：

- 若 stable/rank-1 区 single 与 group 相同，而 unstable/high-rank 区 group 显著更一致，核心故事成立;
- 若 group 在所有区域都不优于 best single，理论存在性仍正确，但现实论文主张被否定;
- 若 group 仅在未配平能量时占优，则发现的是 intervention strength，不是正确 unit;

- 若 BCC 高但 causal curve 不一致，说明 dynamic contribution 仍不足以定义语义因果单元，需要引入 gradient/mediation observable。

这比立刻训练新 SAE 信息增益更高，因为它先验证“我们到底有没有找到值得蒸馏的对象”。

18. 已证明、经典、经验假设与新颖性候选清单

18.1 已在上一轮完整推导中证明

- **THM-CBSM-001**：无重叠理想模型下，finest balanced partitions 与 maximum-cardinality exact covers 对应；仅作特殊模型结果。
- **THM-CBSM-002**：BCC 的 sharp bound 与 equality characterization。
- **THM-CBSM-003**：PSC 的 projector-distance 恒等式与 equality characterization。
- **THM-CBSM-004**：group gauge 与理想 split/merge invariance。
- **THM-CBSM-005**：Hadamard family 中 $BCC=PSC=1$ ，而 $PW-MCC = q^{-1/2} \rightarrow 0$ 。
- **LEM/THM-CBSM-006/007**：有限候选 family 下的 margin recovery 与有界集中证书。
- **THM-CBSM-008**：精确 balance 的 positive 0-1 circuit 表示。
- **THM-CBSM-009**：同 hook 精确/近似贡献匹配到 downstream intervention transfer。

这些结果的完整证明仍保存在上一轮 derivation package 中。论文主文只需保留 002、004、005、009；001、006-008 更适合附录。

18.2 本报告使用但明确属于经典数学

- principal angles 与 projector geometry；
- Hilbert-space ANOVA/barycenter identity；
- Eckart-Young 最优低秩逼近；
- Hoeffding/经验过程集中；
- spectral clustering、OT、CCA、joint block diagonalization；
- exact cover、oriented-matroid circuits。

18.3 尚待实验的经验假设

- 真实 SAE 中存在足够多的小型 local many-to-many groups；
- matched group 比 best functional single feature 更因果一致；
- group advantage 随 atom instability/effective rank 增大；
- rank-adaptive distillation 改善新 SAE 的稳定性和干预质量。

18.4 当前可主张的新颖性候选

在明确检索范围内，尚未发现先例同时具备：

1. 两侧未知基数的 local SAE group discovery；
2. paired token-dependent decoded contribution matching；
3. multi-seed consensus 与 refusal/ambiguity；
4. 严格公平的 best-feature-vs-group causal comparison；
5. 以 causal-validated consensus rank 决定 feature/block distillation。

这仍必须在实验结果出现后执行 theorem/method-equivalence 级检索。任何其中一项被先例吸收时，都应缩窄为剩余组合，不应维持“first”措辞。

19. 文献与本地原文审计

本报告使用的主来源包括：

- [P18 / ACL 2026 Feature Consistency](#)
- [P04 / Unstable Features, Reproducible Subspaces](#)
- [P23 / Subspace-Aware SAEs](#)
- [Sparse Autoencoders Do Not Find Canonical Units of Analysis](#)
- [MetaSAEs: Joint Training](#)
- [SALVE](#)
- [Stable and Steerable SAEs](#)
- [SAE Subspace Guided Projections / SSPU](#)
- [Do SAEs Capture Concept Manifolds?](#)
- [Semantic Optimal Transport](#)
- [Concept Annotations / FBMP](#)
- [Convergent Learning](#)
- [Universal Sparse Autoencoders](#)
- [Mechanistic Permutability](#)

本轮新增并逐页解析/抽查关键页面的开放 PDF：

文件	来源	SHA-256	关键视觉检查
<code>flovik_2026_salve.pdf</code>	arXiv 开放版本	D8B9FF3420F65D2C60EE9201227AB987B47BE9E10CB0BC1267B96E9A98A26A97	suppression curves; 10 初始化和不同 latent bases
<code>jedryszek_crook_2026_stable_steerable.pdf</code>	arXiv 开放版本	85FFA6C54FA5EC3E794E8593B7EAF771871D4120D4E9EDFD02F0F8AEEC0471B2	steering success 与无效解释/feature collapse 相关表述
<code>wang_et_al_2025_sspu.pdf</code>	ACL Anthology 开放版本	5D2A370C0B018CB703472F8DE7E1B4081F131A9318E3E7A529088D0F778DC927	1024-feature subspace 设定与主结果表

OpenReview 的 SSPU PDF endpoint 返回 403 后，改用 ACL Anthology 的合法开放版本，没有绕过访问控制。文献检索冻结日为 2026-08-27；未来新论文可能改变新颖性边界。

20. 最终研究判断

这个方向是 solid 的，但“总有解”需要改成更精确的话：**全字典层面通常存在平凡近似解；小型、语义纯、跨 seed 可复现且因果可交换的局部解不保证存在**。正是这种不保证，才使算法的 ambiguity/refusal 能力和真实实证变得科学上重要。

上一轮数学最有价值的部分并不是 exact cover 的复杂性，而是三条非常直接的逻辑链：

basis/split ambiguity $\Rightarrow$ one-to-one metric can fail,

matched dynamic contribution $\Rightarrow$ same-hook intervention transfer,

consensus spectral rank $\Rightarrow$ distill as one feature or preserve a block.

论文成败最终取决于一个实证事实：在真正困难的 unstable/high-rank concepts 上，经过严格能量、覆盖和选择预算配平后，matched group 是否比最佳单 feature 更稳定地改变同一行为。如果答案是肯定的，数学会让结果成为原理而非现象；如果答案是否定的，我们也会明确知道应转向稳定单 feature 训练，而不是继续堆叠更复杂的 subspace machinery。

PART II

完整数学推导与证明

所有定义、假设、定理、证明、有限样本条件与边界案例集中呈现。

0. Status and claim discipline

- Working name: **Contribution-Balanced Subspace Matching (CBSM)**.
- Mathematical status: the population results and bounded finite-sample results below have complete internal proofs. The finite-sample theorem is deliberately limited to a finite candidate family fixed before the audit sample is seen.
- Novelty status: **paper-level candidate, not verified as new mathematics**. Spectral many-to-many matching, principal angles, joint block diagonalization, sparse subset selection, and margin perturbation arguments are classical. The candidate contribution is their SAE-specific organization around the *finest additive contribution-balanced partition* and a mandatory ambiguity/refusal output.
- Empirical status: not yet tested on real SAE activations.

1. Target

Given two SAEs trained at the same model site with different random seeds, automatically find local many-to-many pairs

$$(I_r^{(A)}, I_r^{(B)}), \quad r = 1, \dots, R,$$

and measure whether each pair represents both the same decoder subspace and the same input-dependent additive contribution. No preferred one-dimensional basis is assumed.

2. An identifiability boundary

A decoder matrix alone cannot determine a semantic partition. The same decoder

$$D = [e_1 \ e_2]$$

is compatible with independent codes, interpreted as two factors, and perfectly coupled codes, interpreted as one compound factor. More strongly, if

$$X \sim N(0, I_q),$$

then $Q^T X$ has the same distribution for every $Q \in O(q)$. No unsupervised statistic of X can choose a preferred one-dimensional basis; the invariant object is the full q -dimensional subspace.

CBSM therefore does not claim to recover a metaphysical semantic ontology. It targets the finest decomposition reproducible as an additive vector-valued process across SAE runs. Semantic labels and interventions are subsequent validation layers.

3. Invariant observable

Let (Ω, F, P) be the input probability space. For seed $s \in \{A, B\}$, write

$$\hat{x}^{(s)}(\omega) = b^{(s)} + \sum_{i=1}^{m_s} d_i^{(s)} z_i^{(s)}(\omega).$$

Use the Hilbert space

$$H = L_2(P; R^d), \quad \langle f, g \rangle_H = E \left[f(\omega)^T g(\omega) \right].$$

The centered contribution process of feature i is

$$\phi_i^{(s)}(\omega) = d_i^{(s)} \left(z_i^{(s)}(\omega) - E z_i^{(s)} \right). \quad (3.1)$$

For $I \subseteq [m_s]$, define its aggregate contribution

$$\Phi_I^{(s)} = \sum_{i \in I} \phi_i^{(s)}. \quad (3.2)$$

Centering separates token-varying structure from the bias/mean component. Mean-contribution consistency must be reported separately so that centering cannot hide a seed-dependent bias.

3.1 Efficient kernel identity

$$\left\langle \phi_i^{(s)}, \phi_j^{(t)} \right\rangle_H = \left(d_i^{(s)} \right)^T d_j^{(t)} \text{Cov} \left(z_i^{(s)}, z_j^{(t)} \right). \quad (3.3)$$

With n shared token positions and centered code matrices Z_s , the empirical paired contribution kernel is

$$\hat{K}^{st} = \left(D_s^T D_t \right) \odot \left(\frac{1}{n} Z_s^T Z_t \right). \quad (3.4)$$

Thus no vectors in R^{nd} need be materialized.

4. Finest balanced partition

Definition 4.1 (balanced and partition-indecomposable pair)

A pair (I, J) with $\emptyset \neq I \subseteq [m_A]$ and $\emptyset \neq J \subseteq [m_B]$ is balanced if

$$\Phi_I^{(A)} = \Phi_J^{(B)} \quad \text{in } H. \quad (4.1)$$

It is **partition-indecomposable** if there do not exist disjoint nonempty decompositions

$$I = I_1 \cup I_2, \quad J = J_1 \cup J_2$$

for which both (I_1, J_1) and (I_2, J_2) are balanced. This is deliberately weaker than set-inclusion minimality: a one-sided zero-sum remainder must not be used to manufacture an inadmissible block with no feature on the other seed.

Definition 4.2 (paired balanced partition)

Fix matched supports $A_0 \subseteq [m_A]$ and $B_0 \subseteq [m_B]$ satisfying $\Phi_{A_0}^{(A)} = \Phi_{B_0}^{(B)}$. A family

$$\Pi = \{ (I_r, J_r) \}_{r=1}^R \quad (4.2)$$

is a paired balanced partition when the I_r partition A_0 , the J_r partition B_0 , and every pair is balanced. A finest partition maximizes R . Features outside A_0 or B_0 are unmatched; their contribution energy is reported rather than forcibly matched. In the special case $A_0 = [m_A]$ and $B_0 = [m_B]$, this is a partition of both full dictionaries.

THM-CBSM-001 (exact-cover characterization)

Let A be the hypergraph of all partition-indecomposable balanced pairs contained in $A_0 \times B_0$. Finest balanced partitions are exactly the maximum-cardinality exact covers of A_0 and B_0 by hyperedges in A . In particular:

1. if the members of A are disjoint and cover both feature sets, they form the unique finest partition;
2. two distinct maximum-cardinality exact covers are a certificate that additive observables do not identify a unique hard partition.

Proof

If a balanced block (I, J) is partition-decomposable, split it into its two nonempty balanced parts. Because the feature sets are finite, repeating this operation terminates in partition-indecomposable balanced pairs. Balance of the second part follows explicitly from

$$\left(\phi_I^{(A)} - \phi_{I_1}^{(A)} \right) - \left(\phi_J^{(B)} - \phi_{J_1}^{(B)} \right) = \phi_{I_2}^{(A)} - \phi_{J_2}^{(B)} = 0.$$

Therefore every block of a finest partition must be partition-indecomposable; otherwise it can be split and the number of blocks increases. Conversely, every exact cover by partition-indecomposable balanced pairs is a balanced partition. Maximizing the number of blocks is therefore exactly the maximum-cardinality exact-cover problem. The two consequences follow immediately. $\square$

Corollary 4.3 (orthogonal block model)

Suppose there are mutually orthogonal closed subspaces

$$H = H_1 \oplus \cdots \oplus H_R \oplus H_\perp$$

and partitions I_r, J_r such that

$$\phi_i^{(A)} \in H_r \ (i \in I_r), \quad \phi_j^{(B)} \in H_r \ (j \in J_r), \quad \phi_{I_r}^{(A)} = \phi_{J_r}^{(B)} \neq 0.$$

Assume, more strongly, that the only balanced subpairs (I, J) with $I \subseteq I_r$ and $J \subseteq J_r$ are $(\emptyset, \emptyset)$ and (I_r, J_r) , and that neither seed has a nonempty zero-sum subset inside a block. Then the displayed pairs form the unique finest balanced partition.

Proof

Project any balance equation onto each H_r . Orthogonality forces balance separately in each block. The atomicity and no-one-sided-zero-sum assumptions imply that any balanced pair intersecting block r contains either all of (I_r, J_r) or none of it. Thus every balanced partition is obtained by grouping whole displayed pairs. Maximizing the number of blocks leaves each pair separate, and that partition is unique. $\square$

5. Two complementary consistency coordinates

Contribution equality and decoder-span equality answer different questions and must both be shown.

Definition 5.1 (balanced contribution consistency)

For nonzero $U, V \in H$, define

$$\text{BCC}(U, V) = \frac{2\langle U, V \rangle_H}{\|U\|_H^2 + \|V\|_H^2} = 1 - \frac{\|U - V\|_H^2}{\|U\|_H^2 + \|V\|_H^2}. \quad (5.1)$$

For a match (I, J) , take $U = \phi_I^{(A)}$ and $V = \phi_J^{(B)}$.

THM-CBSM-002 (sharp BCC characterization)

$$-1 \leq \text{BCC}(U, V) \leq 1,$$

and $\text{BCC}(U, V) = 1$ if and only if $U = V$ in H .

Proof

$$2 |\langle U, V \rangle| \leq 2 \|U\| \|V\| \leq \|U\|^2 + \|V\|^2.$$

This proves the range. The second form in (5.1) equals one exactly when $\|U - V\| = 0$. $\square$

Definition 5.2 (projector subspace consistency)

Let

$$S_I^{(A)} = \text{span} \{d_i^{(A)} : i \in I\}, \quad S_J^{(B)} = \text{span} \{d_j^{(B)} : j \in J\},$$

with orthogonal projectors P_I, Q_J and ranks r_I, r_J . Define

$$\text{PSC}(I, J) = \frac{2 \text{tr}(P_I Q_J)}{r_I + r_J} = 1 - \frac{\|P_I - Q_J\|_F^2}{r_I + r_J}. \quad (5.2)$$

Here groups with zero decoder rank are excluded from PSC and reported as degenerate.

THM-CBSM-003 (sharp PSC characterization)

$$0 \leq \text{PSC}(I, J) \leq 1,$$

and $\text{PSC}(I, J) = 1$ if and only if the decoder spans are equal.

Proof

For orthogonal projectors,

$$\|P_I - Q_J\|_F^2 = r_I + r_J - 2 \text{tr}(P_I Q_J) \geq 0.$$

Also $\text{tr}(P_I Q_J) \geq 0$. Equality to one is equivalent to $P_I = Q_J$, hence to equality of their ranges. $\square$

Reporting rule

$$\text{CBSM}(I, J) = (\text{BCC}(I, J), \text{PSC}(I, J)). \quad (5.3)$$

Also report both group sizes, both ranks, unmatched energy, mean-contribution error, and ambiguity. A scalar average could hide “same span, different computation” or “same aggregate, bloated span.”

6. Gauge and split/merge invariance

THM-CBSM-004 (group gauge invariance)

Write an uncentered group contribution as

$$Y_I(\omega) = D_I z_I(\omega).$$

For every compatible invertible matrix R , the reparameterization

$$D'_I = D_I R, \quad z'_I = R^{-1} z_I \quad (6.1)$$

leaves Y_I , Φ_I , and the decoder span unchanged. Thus BCC and PSC are invariant under arbitrary within-group changes of basis, not only permutations or rotations. More generally, any rectangular split/merge refactorization satisfying

$$D_I z_I(\omega) = D'_J z'_J(\omega) \quad P\text{-almost surely}$$

has perfect BCC; it has perfect PSC exactly when the two decoder ranges coincide.

This is an invariance of the represented group process. A general R need not preserve a particular SAE encoder architecture, nonnegativity, or sparsity constraint.

Proof

$D'_I z'_I = D_I R R^{-1} z_I = D_I z_I$ pointwise, and centering preserves equality. Right multiplication by an invertible matrix preserves column space. THM-CBSM-002 and THM-CBSM-003 finish the proof. $\square$

7. Separation from one-to-one PW-MCC

THM-CBSM-005 (perfect block agreement with vanishing PW-MCC)

Let $q \geq 2$ admit a real Hadamard matrix H_q , put $Q = H_q / \sqrt{q}$, and let $X \sim N(0, I_q)$. Define signed-ReLU dictionaries

$$D_A = [I_q \quad -I_q], \quad z_A(X) = \begin{bmatrix} X_+ \\ (-X)_+ \end{bmatrix},$$

and

$$D_B = [Q \quad -Q], \quad z_B(X) = \begin{bmatrix} (Q^T X)_+ \\ (-Q^T X)_+ \end{bmatrix}.$$

Both reconstruct X exactly. Matching all $2q$ features to all $2q$ features gives

$$\text{BCC} = 1, \quad \text{PSC} = 1,$$

whereas the optimal absolute-cosine PW-MCC is

$$\text{PW-MCC} = q^{-1/2}.$$

The gap tends to one along the Sylvester Hadamard sequence $q = 2^k$.

Proof

For every scalar u , $u = u_+ - (-u)_+$. Hence

$$D_A z_A(X) = X, \quad D_B z_B(X) = Q(Q^T X) = X.$$

The aggregate centered contribution processes are identical, so BCC is one. Both spans equal R^q , so PSC is one. Every column of D_A is a signed coordinate vector and every column of D_B a signed Hadamard vector; every absolute inner product is $1 / \sqrt{q}$. Any perfect assignment therefore has that mean. $\square$

This is a separating witness, not universal dominance. The 2015 correlation-spectral method may also place all units into one cluster here; CBSM adds exact additive-balance, subspace-equality, and ambiguity certificates.

8. Finite-sample certificate

Fix, before seeing an audit sample, a finite candidate family $\mathcal{C}$. Population means used for centering are either known or estimated on a separate split and then held fixed; conditional on those fixed centering constants, the audit observations are i.i.d. Define

$$r(I, J) = \frac{\|\Phi_I^{(A)} - \Phi_J^{(B)}\|_H^2}{\|\Phi_I^{(A)}\|_H^2 + \|\Phi_J^{(B)}\|_H^2}, \quad (8.1)$$

and let $\hat{r}(I, J)$ be its audit-sample estimate. Suppose true minimal blocks have residual at most ρ_* , while false candidates have residual at least $\rho_* + \Delta$.

LEM-CBSM-006 (finite-family margin recovery)

If

$$\sup_{(I, J) \in \mathcal{C}} |\hat{r}(I, J) - r(I, J)| < \frac{\Delta}{2}, \quad (8.2)$$

then thresholding at $\rho_* + \Delta / 2$ separates every true candidate from every false candidate in $\mathcal{C}$.

Proof

A true candidate satisfies

$$\hat{r} < \rho_* + \frac{\Delta}{2},$$

whereas a false candidate satisfies

$$\hat{r} > \rho_* + \Delta - \frac{\Delta}{2} = \rho_* + \frac{\Delta}{2}.$$

Thus the threshold separates them. $\square$

The next result supplies one explicit sufficient condition for (8.2).

THM-CBSM-007 (bounded finite-sample certificate)

For every $(I, J) \in \mathcal{C}$, write

$$W_{I, J} = \|\Phi_I^{(A)} - \Phi_J^{(B)}\|_2^2, \quad A_{I, J} = \|\Phi_I^{(A)}\|_2^2 + \|\Phi_J^{(B)}\|_2^2.$$

Suppose, almost surely and uniformly over $\mathcal{C}$,

$$0 \leq W_{I, J} \leq B, \quad 0 \leq A_{I, J} \leq B, \quad EA_{I, J} \geq v > 0. \quad (8.3)$$

If $0 < \Delta \leq 2$ and

$$n > \frac{72B^2}{v^2\Delta^2} \log \frac{4|C|}{\delta}, \quad (8.4)$$

then, with probability at least $1 - \delta$,

$$\sup_{(I,J) \in \mathcal{C}} |\hat{r}(I,J) - r(I,J)| < \frac{\Delta}{2}. \quad (8.5)$$

Consequently LEM-CBSM-006 recovers all true candidates in $\mathcal{C}$.

Proof

Put

$$t = B \sqrt{\frac{1}{2n} \log \frac{4|C|}{\delta}}.$$

Let $\mu_W = EW$, $\mu_A = EA$, and let $\hat{\mu}_W, \hat{\mu}_A$ denote their sample means for the candidate under consideration. Hoeffding's inequality and a union bound over the numerator and denominator of every candidate give, with probability at least $1 - \delta$,

$$|\hat{\mu}_W - \mu_W| \leq t, \quad |\hat{\mu}_A - \mu_A| \leq t \quad (8.6)$$

simultaneously. Because $\|U - V\|^2 \leq 2(\|U\|^2 + \|V\|^2)$, $\mu_W / \mu_A \leq 2$. The sample-size assumption and $\Delta \leq 2$ imply $t < v/2$, hence $\hat{\mu}_A > v/2$. On the event (8.6),

$$\left| \frac{\hat{\mu}_W}{\hat{\mu}_A} - \frac{\mu_W}{\mu_A} \right| \leq \frac{t}{\hat{\mu}_A} + \frac{\mu_W t}{\mu_A \hat{\mu}_A} \leq \frac{2t}{v} + \frac{4t}{v} = \frac{6t}{v} < \frac{\Delta}{2}.$$

This holds uniformly over $\mathcal{C}$. $\square$

If candidates are selected using the same data, this theorem is not a post-selection certificate without a uniform complexity bound. The default protocol uses one split to generate candidates and a disjoint split to certify them. For sub-exponential rather than bounded contributions, Bernstein concentration gives the same qualitative rate

$$n = O\left(\frac{\kappa^4}{\Delta^2} \log \frac{|C|}{\delta}\right), \quad (8.7)$$

up to denominator lower bounds. This rate remains a roadmap claim until constants and tail assumptions are fully tracked.

9. Optimization form and algorithm

Let Ψ_A, Ψ_B contain flattened empirical contribution processes as columns. For binary selectors a, b ,

$$\left\| \Psi_A a - \Psi_B b \right\|_2^2 = \begin{bmatrix} a \\ b \end{bmatrix}^T \begin{bmatrix} K^{AA} & -K^{AB} \\ -K^{BA} & K^{BB} \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix}. \quad (9.1)$$

For an anchor feature i , solve the local mixed-integer quadratically constrained problem

$$\min_{a,b} \quad \|1^T a + 1^T b\|, \text{ subject to } \|a\|_i = 1, \quad a \in \{0,1\}^p, \quad b \in \{0,1\}^q, \text{ and } \left\| \Psi_A a - \Psi_B b \right\|_2^2 \leq \varepsilon^2 (\| \Psi_A a \|_2^2 + \| \Psi_B b \|_2^2). \quad (9.2)$$

The complete algorithm is:

1. Compute centered sparse codes on shared tokens and the four kernels in (3.4).
2. On a discovery split, generate small cross-seed neighborhoods from contribution affinity, optional conditional-dependence edges, and decoder-span leakage. These only prune candidates.
3. Solve (9.2) from every anchor and enumerate tied or near-tied partition-indecomposable solutions.
4. Treat candidate subset pairs as hyperedges and solve the maximum-cardinality, minimum-residual exact-cover problem.
5. Retain all statistically indistinguishable covers rather than silently choosing one.
6. On an independent audit split, certify BCC, PSC, mean contribution, unmatched energy, the nearest competing residual, group condition number, and feature leverage.
7. Return a hard match only if the cover is unique at the declared tolerance; otherwise return an ambiguity hypergraph or a merged block.

The combinatorics are intentional. Spectral clustering is a valid initializer, but making it the final answer would reproduce Li et al. (2015) and would not certify additive interchangeability.

THM-CBSM-008 (positive-circuit representation)

Let $\Psi = [\Psi_A \ - \ \Psi_B]$ and let

$$G = \Psi^T \Psi = \begin{bmatrix} K^{AA} & -K^{AB} \\ -K^{BA} & K^{BB} \end{bmatrix} \succeq 0. \quad (9.3)$$

For a selector $x = (a, b) \in \{0, 1\}^{m_A + m_B}$ with both a and b nonzero, the following are equivalent:

1. $(\text{supp } a, \text{supp } b)$ is balanced;
2. $\Psi x = 0$;
3. $x^T G x = 0$;
4. $G x = 0$.

If neither seed contains a nonempty one-sided zero-sum subset, the partition-indecomposable balanced pairs are precisely the support-minimal binary vectors in $\ker G$ having nonempty support on both sides. Thus exact CBSM discovery is a positive 0--1 circuit-enumeration problem followed by exact cover.

Proof

By construction,

$$\Psi x = \Psi_A a - \Psi_B b = \phi_{\text{supp } a}^{(A)} - \phi_{\text{supp } b}^{(B)},$$

so (1) and (2) are equivalent. Also $x^T G x = \|\Psi x\|_2^2$, proving (2) $\Leftrightarrow$ (3). Because $G \succeq 0$, write $G = R^T R$; then $x^T G x = \|R x\|^2 = 0$ if and only if $R x = 0$, which is equivalent to $G x = R^T R x = 0$. Finally, under the no-one-sided-zero-sum assumption, a proper binary kernel vector below x leaves another nonzero binary kernel vector as its disjoint complement. Hence support-minimality and partition-indecomposability coincide. $\square$

This theorem connects the proposed object to oriented-matroid circuits and sparse null-vector algorithms. That connection is a computational tool and a prior-art warning, not a claim that circuit theory itself is new.

10. Downstream intervention transfer

Centered contribution agreement must be combined with agreement of the group means. Define the uncentered contribution $Y_I^{(s)} = \sum_{i \in I} d_i^{(s)} z_i^{(s)}$.

THM-CBSM-009 (causal interchangeability at a shared hook)

Let $h(\omega)$ be the residual-stream state at a shared hook and let F be any deterministic measurable downstream computation.

1. If $Y_I^{(A)} = Y_J^{(B)}$ almost surely, then group ablation is exactly interchangeable:

$$F(h - Y_I^{(A)}) = F(h - Y_J^{(B)}) \quad \text{almost surely.} \quad (10.1)$$

2. If F is L -Lipschitz, then

$$E \left\| F(h - Y_I^{(A)}) - F(h - Y_J^{(B)}) \right\|^2 \leq L^2 E \left\| Y_I^{(A)} - Y_J^{(B)} \right\|^2. \quad (10.2)$$

Proof

The first claim follows by substituting equal arguments into F . For the second, apply the Lipschitz inequality pointwise to the two arguments, square it, and take expectations. $\square$

Thus exact BCC together with equal mean contributions implies exact transfer of same-hook group ablation through *any* downstream network. Approximate contribution balance controls downstream drift whenever a local or global Lipschitz estimate is defensible. This guarantee is stronger than decoder cosine, activation correlation, or span equality alone, although it does not establish a human-semantic label.

11. Falsifiers and boundary cases

1. **Whole-dictionary collapse.** If the only certified balance is the full reconstruction, local concepts are not identified by these observables.
2. **Competing covers.** Two statistically indistinguishable maximum-cardinality covers require an ambiguity report.
3. **Cancellation.** BCC can be one while groups contain large canceling terms. PSC, condition number, and per-feature leverage must expose this.
4. **Same span, different function.** PSC can be one while BCC is low.
5. **Same aggregate, enlarged span.** BCC can be one while PSC is below one due to unused or canceling decoder directions.
6. **Rare occupancy.** Estimates of (3.3) can be driven by a few tokens; effective sample size and bootstrap stability are mandatory.
7. **Data reuse.** Discovery and certification on the same sample invalidate the simple finite-family theorem.

12. Narrow candidate contribution

Existing SAE consistency work matches atoms, measures a hand-selected or global span, clusters correlation/dependence graphs, or learns blocks during training. CBSM instead defines and searches for the finest cross-seed subset pairs whose **summed vector-valued SAE contributions** agree, and couples this additive certificate to an unequal-dimension projector score and explicit non-identifiability output.

This is the strongest presently defensible claim. It still requires a deeper theorem-equivalence and code search for group-stitching/subset-balance methods before any verified-novel label.

PART III

证明审计、修订历史与可信度边界

保留发现过的错误、修复方式、反例红队和仍未通过的独立审阅门。

Assurance status

The executor completed a line-by-line same-family internal audit and deterministic low-dimensional checks. The proof-checker skill normally requires a fresh reviewer agent. Current execution policy does not authorize spawning one, so the formal independent-review gate is **BLOCKED**. This is not a mathematical counterexample; it means the “verified” label is withheld.

Round 0 issues found and fixed

FIX-001: support-minimal exact-cover statement

- Status/impact: INVALID + GLOBAL in the earlier draft.
- Category: CASE_INCOMPLETE.
- Counterexample: a contained balanced subpair can leave a one-sided zero-sum remainder, which is not an admissible paired block if both sides must be nonempty.
- Fix strategy: WEAKEN_CLAIM.
- Fix: replace set-inclusion minimality by **partition-indecomposability**, define matched supports explicitly, and make unmatched features external to the balanced partition.

FIX-002: uniqueness in the orthogonal block corollary

- Status/impact: UNDERSTATED + LOCAL.
- Category: HIDDEN_ASSUMPTION.
- Counterexample candidate: a one-sided zero-sum subset inside a block can cross-contaminate an alternative cover.
- Fix strategy: STRENGTHEN_ASSUMPTION.
- Fix: require block atomicity and absence of one-sided zero-sum subsets.

FIX-003: zero-rank PSC

- Status/impact: UNCLEAR + LOCAL.
- Category: CASE_INCOMPLETE.
- Fix strategy: STRENGTHEN_ASSUMPTION.
- Fix: exclude zero-rank decoder groups from PSC and report them as degenerate.

FIX-004: arbitrary group gauge versus SAE feasibility

- Status/impact: OVERSTATED + LOCAL.
- Category: SCOPE_OVERCLAIM.
- Fix strategy: WEAKEN_CLAIM.
- Fix: state that GL invariance concerns the represented group process; a general change of basis need not preserve ReLU nonnegativity, sparsity, or a fixed encoder architecture.

FIX-005: audit centering in the finite-sample theorem

- Status/impact: UNJUSTIFIED + GLOBAL for THM-007.

- Category: STOCHASTIC_MODE_CONFUSION.
- Counterexample mechanism: centering each feature by the same audit sample makes the summands dependent, so the quoted i.i.d. Hoeffding step does not directly apply.
- Fix strategy: STRENGTHEN_ASSUMPTION.
- Fix: population means are known or estimated on a separate split and frozen before the audit sample. Conditional on those constants, the audit terms are i.i.d.

FIX-006: “Hadamard sequence”

- Status/impact: UNCLEAR + COSMETIC.
- Category: QUANTIFIER_ERROR.
- Fix strategy: ADD_DERIVATION.
- Fix: specify the Sylvester sequence $q = 2^k$, which exists for every k .

Current theorem-by-theorem audit

Result	Internal status	Counterexample pass	Remaining limitation
THM-001	passes after FIX-001	empty side, zero-sum, crossing cover tested	exact population balance only
Cor. 4.3	passes under strengthened assumptions	two orthogonal blocks and crossed unions tested	atomicity is strong and not observable without testing
THM-002	passes	collinear positive/negative, unequal norms	excludes zero vector
THM-003	passes	unequal ranks, nested spans, orthogonal spans	excludes rank zero
THM-004	passes as algebraic invariance	nonorthogonal shear/scaling	may leave SAE model class
THM-005	passes	$q = 2, 4, 8$ deterministic numerical checks at machine precision	gives separation, not universal dominance
LEM-006	passes	equality at threshold checked; strict audit bound used	assumes a clean population margin
THM-007	passes under stated bounded/fixed-family assumptions	$\Delta \rightarrow 0, \nu \rightarrow 0$, data reuse tested	no adaptive-family guarantee
THM-008	passes	singular Gram and one-sided zero sums tested	exact circuits are combinatorial
THM-009	passes	constant/discontinuous/non-Lipschitz F checked	approximate clause requires Lipschitzness

Inequality audit

1. BCC range uses Cauchy--Schwarz and $2ab \leq a^2 + b^2$; equality at 1 is checked through the residual identity, so there is no missing equal-norm condition.
2. PSC uses the exact orthogonal-projector Frobenius identity.
3. THM-007 uses Hoeffding for variables in $[0, B]$, a union bound over $2 \mid C \mid$ means, and

$$\left| \frac{\hat{\mu}_W}{\hat{\mu}_A} - \frac{\mu_W}{\mu_A} \right| \leq \frac{2t}{\nu} + \frac{4t}{\nu}.$$

The constant 72 is sufficient because $t < B \sqrt{v^2 \Delta^2 / (144 B^2)} = v \Delta / 12$. 4. No limit, derivative, or integral interchange appears in the proved results.

Counterexample red team

- **Whole dictionary only:** valid failure mode, retained as an explicit refusal outcome.
- **Two distinct exact covers:** does not contradict THM-001; it triggers ambiguity.
- **Cancellation:** BCC alone can be perfect with bloated/canceling members; PSC, condition number, and feature leverage are required diagnostics.
- **Same span, wrong computation:** PSC can be one with BCC low.
- **Same sum, extra unused direction:** BCC can be one with PSC below one.
- **Adaptive candidate reuse:** breaks the simple finite-family certificate; discovery/audit splitting is mandatory.
- **Non-Lipschitz downstream map:** arbitrarily small contribution error can cause a finite output jump; THM-009 does not claim otherwise.

External-paper audit note: P23

The P23 appendix calls a piecewise function strictly concave although it is affine below its threshold, and its factor-level orthogonal-uniqueness claim is contradicted by an arbitrary invertible within-block refactorization when only one block is active. CBSM does not depend on either claim.

Verdict

Internal mathematical review found no remaining counterexample to THM-CBSM-001--009 under their current hypotheses. Formal proof-checker verdict remains **BLOCKED / same-family provisional** because no fresh independent reviewer was permitted. Empirical and novelty validation are separate and remain open.

The formal audit TeX source was emitted, but PDF compilation was not performed because no `pdflatex` executable is installed in the workspace runtime.

本卷由以下三个受控源合并生成：goal_aligned_subspace_consistency_research_program.md、DERIVATION_PACKAGE.md、PROOF_AUDIT.md。数学新颖性与经验优越性仍须独立验证。